

Inteligência Artificial – ACH2016


Aula 16 – Regra de Bayes e Redes Bayesianas

Norton Trevisan Roman
(norton@usp.br)

12 de maio de 2019

Regra de Bayes

$$\left. \begin{array}{l} P(a \wedge b) = P(a|b)P(b) \\ P(a \wedge b) = P(b|a)P(a) \end{array} \right\} \rightarrow P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$



$$\left. \begin{array}{l} P(a \wedge b \wedge c) = P(a|b \wedge c)P(b|c)P(c) \\ P(a \wedge b \wedge c) = P(b|a \wedge c)P(a|c)P(c) \end{array} \right\} \rightarrow P(b|a \wedge c) = \frac{P(a|b \wedge c)P(b|c)}{P(a|c)}$$

Regra de Bayes

Exemplo

- Considere o seguinte problema:

Regra de Bayes

Exemplo

- Considere o seguinte problema:
 - 1% das mulheres na idade de 40 anos que fazem exames de rotina têm câncer de mama.

Regra de Bayes

Exemplo

- Considere o seguinte problema:
 - 1% das mulheres na idade de 40 anos que fazem exames de rotina têm câncer de mama.
 - 80% das mulheres com câncer de mama terão mamogramas positivos para câncer

Regra de Bayes

Exemplo

- Considere o seguinte problema:
 - 1% das mulheres na idade de 40 anos que fazem exames de rotina têm câncer de mama.
 - 80% das mulheres com câncer de mama terão mamogramas positivos para câncer
 - 9,6% das mulheres sem câncer de mama também terão mamogramas positivos

Regra de Bayes

Exemplo

- Considere o seguinte problema:
 - 1% das mulheres na idade de 40 anos que fazem exames de rotina têm câncer de mama.
 - 80% das mulheres com câncer de mama terão mamogramas positivos para câncer
 - 9,6% das mulheres sem câncer de mama também terão mamogramas positivos
 - Uma mulher de 40 anos teve um mamograma positivo em um exame de rotina. Qual a probabilidade dela efetivamente ter câncer de mama?

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

$$P(\text{câncer}) = \frac{1}{100} = 0,01$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

$$P(\text{câncer}) = \frac{1}{100} = 0,01$$

$$P(\text{positivo}) = ?$$

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
 - Efeito: mamograma positivo

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
 - Efeito: mamograma positivo
 - Causa: ter (ou não) câncer

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
- Efeito: mamograma positivo
- Causa: ter (ou não) câncer

$$P(\textit{positivo}) = P(\textit{positivo} \wedge \textit{c\^ancer}) + P(\textit{positivo} \wedge \neg \textit{c\^ancer})]$$

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
- Efeito: mamograma positivo
- Causa: ter (ou não) câncer

$$P(\text{positivo}) = P(\text{positivo} \wedge \text{câncer}) + P(\text{positivo} \wedge \neg \text{câncer})$$

$$P(\text{positivo} \wedge \text{câncer}) = P(\text{positivo}|\text{câncer})P(\text{câncer})$$

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
 - Efeito: mamograma positivo
 - Causa: ter (ou não) câncer

$$P(\text{positivo}) = P(\text{positivo} \wedge \text{câncer}) + P(\text{positivo} \wedge \neg \text{câncer})]$$

$$P(\text{positivo} \wedge \text{câncer}) = P(\text{positivo}|\text{câncer})P(\text{câncer})$$

$$P(\text{positivo} \wedge \text{câncer}) = 0,8 \times 0,01 = 0,008$$

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
- Efeito: mamograma positivo
- Causa: ter (ou não) câncer

$$P(\text{positivo}) = P(\text{positivo} \wedge \text{câncer}) + P(\text{positivo} \wedge \neg \text{câncer})]$$

$$P(\text{positivo} \wedge \text{câncer}) = P(\text{positivo}|\text{câncer})P(\text{câncer})$$

$$P(\text{positivo} \wedge \text{câncer}) = 0,8 \times 0,01 = 0,008$$

$$P(\text{positivo} \wedge \neg \text{câncer}) = P(\text{positivo}|\neg \text{câncer})(1 - P(\text{câncer}))$$

Regra de Bayes

Exemplo

- Lembre que a probabilidade de um efeito é obtida somando-se as probabilidades de sua ocorrência em conjunto com todas suas causas
- Efeito: mamograma positivo
- Causa: ter (ou não) câncer

$$P(\text{positivo}) = P(\text{positivo} \wedge \text{câncer}) + P(\text{positivo} \wedge \neg \text{câncer})]$$

$$P(\text{positivo} \wedge \text{câncer}) = P(\text{positivo}|\text{câncer})P(\text{câncer})$$

$$P(\text{positivo} \wedge \text{câncer}) = 0,8 \times 0,01 = 0,008$$

$$P(\text{positivo} \wedge \neg \text{câncer}) = P(\text{positivo}|\neg \text{câncer})(1 - P(\text{câncer}))$$

$$P(\text{positivo} \wedge \neg \text{câncer}) = \frac{9,6}{100} \times (1 - 0,01) = 0,09504$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

$$P(\text{câncer}) = \frac{1}{100} = 0,01$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

$$P(\text{câncer}) = \frac{1}{100} = 0,01$$

$$P(\text{positivo}) = 0,008 + 0,09504 = 0,10304$$

Regra de Bayes

Exemplo

- $P(\text{câncer}|\text{positivo}) = ?$

$$P(\text{câncer}|\text{positivo}) = \frac{P(\text{positivo}|\text{câncer})P(\text{câncer})}{P(\text{positivo})}$$

$$P(\text{positivo}|\text{câncer}) = \frac{80}{100} = 0,8$$

$$P(\text{câncer}) = \frac{1}{100} = 0,01$$

$$P(\text{positivo}) = 0,008 + 0,09504 = 0,10304$$

$$P(\text{câncer}|\text{positivo}) = \frac{0,8 \times 0,01}{0,10304} \approx 0,0776 = 7,76\%$$

Redes Bayesianas

Redes Bayesianas

- Trata-se de uma estrutura de dados

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis
- Grafo dirigido acíclico

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis
- Grafo dirigido acíclico
 - Nós: variáveis aleatórias (discretas ou contínuas)

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis
- Grafo dirigido acíclico
 - Nós: variáveis aleatórias (discretas ou contínuas)
 - Cada nó tem uma tabela de distribuição de probabilidade que quantifica a influência dos pais nesse nó

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis
- Grafo dirigido acíclico
 - Nós: variáveis aleatórias (discretas ou contínuas)
 - Cada nó tem uma tabela de distribuição de probabilidade que quantifica a influência dos pais nesse nó
 - $P(X_i | \text{pais}(X_i))$

Redes Bayesianas

- Trata-se de uma estrutura de dados
 - Representa a distribuição conjunta de probabilidade para um conjunto de variáveis
 - Representa dependências entre variáveis
- Grafo dirigido acíclico
 - Nós: variáveis aleatórias (discretas ou contínuas)
 - Cada nó tem uma tabela de distribuição de probabilidade que quantifica a influência dos pais nesse nó
 - $P(X_i | \text{pais}(X_i))$
 - Arestas: unem variáveis interdependentes

Redes Bayesianas


Topologia

Topologia

- A topologia da rede especifica as relações de independência condicional existentes:

Topologia


- A topologia da rede especifica as relações de independência condicional existentes:



Fonte: Adaptado de AIMA. Russell & Norvig.

Topologia

- A topologia da rede especifica as relações de independência condicional existentes:




Fonte: Adaptado de AIMA. Russell & Norvig.

- *Clima* é independente das demais variáveis

Topologia

- A topologia da rede especifica as relações de independência condicional existentes:



Fonte: Adaptado de AIMA. Russell & Norvig.

- *Clima* é independente das demais variáveis
- *Broca* e *Dor* são condicionalmente independentes, dada *Cárie*

Redes Bayesianas

Exemplo

- Você está no trabalho...

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou
 - Contudo, a vizinha, Maria, não ligou

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou
 - Contudo, a vizinha, Maria, não ligou
 - Algumas vezes o alarme dispara por conta de pequenos tremores

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou
 - Contudo, a vizinha, Maria, não ligou
 - Algumas vezes o alarme dispara por conta de pequenos tremores
 - Há um ladrão?

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou
 - Contudo, a vizinha, Maria, não ligou
 - Algumas vezes o alarme dispara por conta de pequenos tremores
 - Há um ladrão?
- Variáveis:

Exemplo

- Você está no trabalho...
 - Seu vizinho, João, liga dizendo que o alarme da sua casa disparou
 - Contudo, a vizinha, Maria, não ligou
 - Algumas vezes o alarme dispara por conta de pequenos tremores
 - Há um ladrão?
- Variáveis:
 - *Ladrão, Terremoto, Alarme, JoãoLiga, MariaLiga*

Redes Bayesianas

Exemplo – Relações causais (i.e., regras)

Exemplo – Relações causais (i.e., regras)

- Um ladrão pode disparar o alarme

Exemplo – Relações causais (i.e., regras)

- Um ladrão pode disparar o alarme
- Um terremoto pode disparar o alarme

Exemplo – Relações causais (i.e., regras)

- Um ladrão pode disparar o alarme
- Um terremoto pode disparar o alarme
- O alarme pode fazer com que Maria ligue

Exemplo – Relações causais (i.e., regras)

- Um ladrão pode disparar o alarme
- Um terremoto pode disparar o alarme
- O alarme pode fazer com que Maria ligue
 - Embora ela nem sempre o escute

Exemplo – Relações causais (i.e., regras)

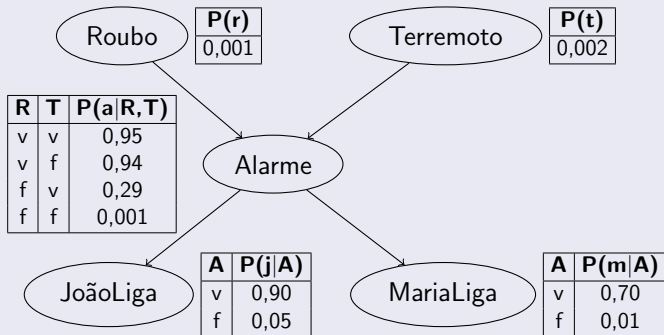
- Um ladrão pode disparar o alarme
- Um terremoto pode disparar o alarme
- O alarme pode fazer com que Maria ligue
 - Embora ela nem sempre o escute
- O alarme pode fazer com que João ligue

Exemplo – Relações causais (i.e., regras)

- Um ladrão pode disparar o alarme
- Um terremoto pode disparar o alarme
- O alarme pode fazer com que Maria ligue
 - Embora ela nem sempre o escute
- O alarme pode fazer com que João ligue
 - Embora algumas vezes ele confunda o telefone com o alarme

Redes Bayesianas

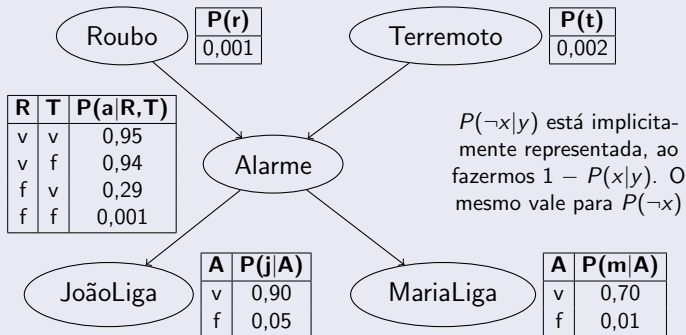
Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas


Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas

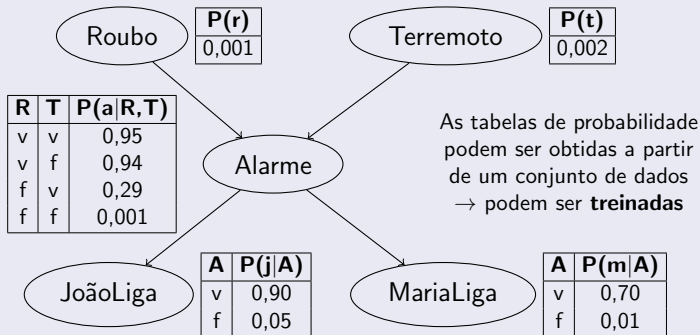
Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas

Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

Probabilidades resumem um conjunto potencialmente infinito de causas, ao definirem valores para algo não acontecer (como o alarme não soar), sem se preocupar em definir suas causas.

Semântica Global

- Define a distribuição conjunta total como sendo o produto das distribuições condicionais locais

$$P(X_1 = x_1, \dots, X_n = x_n) = P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(X_i))$$

- $\text{pais}(X_i)$ – valores das variáveis pais de X_i na rede

Semântica Global

- Define a distribuição conjunta total como sendo o produto das distribuições condicionais locais

$$P(X_1 = x_1, \dots, X_n = x_n) = P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(X_i))$$

- $\text{pais}(X_i)$ – valores das variáveis pais de X_i na rede
- Exemplo:
 - João e Maria ligam porque o alarme soou, mas não há nem terremoto, nem ladrão

Redes Bayesianas


Semântica Global

- Define a distribuição conjunta total como sendo o produto das distribuições condicionais locais

$$P(X_1 = x_1, \dots, X_n = x_n) = P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(X_i))$$

- $\text{pais}(X_i)$ – valores das variáveis pais de X_i na rede
- Exemplo:
 - João e Maria ligam porque o alarme soou, mas não há nem terremoto, nem ladrão

$$\begin{aligned} P(j \wedge m \wedge a \wedge \neg r \wedge \neg t) \\ &= P(j|a)P(m|a)P(a|\neg r \wedge \neg t)P(\neg r)P(\neg t) \\ &= 0,90 \times 0,70 \times 0,001 \times 0,999 \times 0,998 \approx 0,00063 \end{aligned}$$



Fonte: Slides de AIMA. Russell & Norvig.

Redes Bayesianas

Construção de Redes Bayesianas

Redes Bayesianas

Construção de Redes Bayesianas

- Considere a regra da cadeia:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1)$$

Verdadeira para todo conjunto de variáveis

Redes Bayesianas

Construção de Redes Bayesianas

- Considere a regra da cadeia:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) \quad \text{Verdadeira para todo conjunto de variáveis}$$

- Compare-a com a interpretação semântica de uma rede bayesiana:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(x_i))$$

Construção de Redes Bayesianas

- Considere a regra da cadeia:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) \quad \text{Verdadeira para todo conjunto de variáveis}$$

- Compare-a com a interpretação semântica de uma rede bayesiana:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(x_i))$$

- $P(x_i | x_{i-1}, \dots, x_1) = P(x_i | \text{pais}(x_i))$, se $\text{pais}(x_i) \subseteq \{x_{i-1}, \dots, x_1\}$

Construção de Redes Bayesianas

- Considere a regra da cadeia:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) \quad \text{Verdadeira para todo conjunto de variáveis}$$

- Compare-a com a interpretação semântica de uma rede bayesiana:

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{pais}(x_i))$$

- $P(x_i | x_{i-1}, \dots, x_1) = P(x_i | \text{pais}(x_i))$, se $\text{pais}(x_i) \subseteq \{x_{i-1}, \dots, x_1\}$
- Condição satisfeita se rotularmos os nós em uma ordem consistente com a ordem parcial implícita no grafo

Redes Bayesianas

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
- Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
 - Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais
- Método:

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
 - Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais
- Método:
 - Escolha uma ordem para as variáveis X_n, \dots, X_1

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
 - Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais
- Método:
 - Escolha uma ordem para as variáveis X_n, \dots, X_1
 - Para $i = 1$ até n :

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
 - Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais
- Método:
 - Escolha uma ordem para as variáveis X_n, \dots, X_1
 - Para $i = 1$ até n :
 - Adicione X_i à rede

Construção de Redes Bayesianas

- $P(X_i | X_{i-1}, \dots, X_1) = P(X_i | \text{pais}(X_i))$
 - Redes bayesianas são representações corretas do domínio somente se cada nó for condicionalmente independente de seus predecessores na ordenação, dados seus pais
- Método:
 - Escolha uma ordem para as variáveis X_n, \dots, X_1
 - Para $i = 1$ até n :
 - Adicione X_i à rede
 - Selecione pais de X_i de X_1, \dots, X_{i-1} tais que $P(X_i | \text{pais}(X_i)) = P(X_i | X_{i-1}, \dots, X_1)$

Redes Bayesianas

Construção de Redes Bayesianas

- Exemplo de teste para os pais:

Redes Bayesianas

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M

Redes Bayesianas

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M
 - Maria ligar (M) é influenciada pelo fato de ter um ladrão (R) ou terremoto (T)

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M
 - Maria ligar (M) é influenciada pelo fato de ter um ladrão (R) ou terremoto (T)
 - Não diretamente, apenas por meio do alarme (A)

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M
 - Maria ligar (M) é influenciada pelo fato de ter um ladrão (R) ou terremoto (T)
 - Não diretamente, apenas por meio do alarme (A)
 - Dado o estado do alarme, João ligar (J) não influencia o fato de Maria ligar ou não

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M
 - Maria ligar (M) é influenciada pelo fato de ter um ladrão (R) ou terremoto (T)
 - Não diretamente, apenas por meio do alarme (A)
 - Dado o estado do alarme, João ligar (J) não influencia o fato de Maria ligar ou não
 - Com base nessas crenças, podemos dizer que

$$P(M|J, A, T, R) = P(M|A)$$

Construção de Redes Bayesianas

- Exemplo de teste para os pais:
 - Ordem: R, T, A, J, M
 - Maria ligar (M) é influenciada pelo fato de ter um ladrão (R) ou terremoto (T)
 - Não diretamente, apenas por meio do alarme (A)
 - Dado o estado do alarme, João ligar (J) não influencia o fato de Maria ligar ou não
 - Com base nessas crenças, podemos dizer que

$$P(M|J, A, T, R) = P(M|A)$$

- E nossa escolha foi correta, para mariaLigar

Redes Bayesianas

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:
 - Primeiro adicione as “causas principais”

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:
 - Primeiro adicione as “causas principais”
 - Em seguida, as variáveis que elas influenciam

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:
 - Primeiro adicione as “causas principais”
 - Em seguida, as variáveis que elas influenciam
 - Repita, até atingir as folhas – variáveis que não influenciam ninguém

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:
 - Primeiro adicione as “causas principais”
 - Em seguida, as variáveis que elas influenciam
 - Repita, até atingir as folhas – variáveis que não influenciam ninguém
- E se escolhermos a ordem errada?

Construção de Redes Bayesianas

- Qual então é a ordem correta de nós?
 - Uma dica é começar com quem influencia outros nós, mas não sofre influência de ninguém
 - A ordem correta de inclusão de nós é, então:
 - Primeiro adicione as “causas principais”
 - Em seguida, as variáveis que elas influenciam
 - Repita, até atingir as folhas – variáveis que não influenciam ninguém
- E se escolhermos a ordem errada?
 - Suponha que escolhemos a ordem: M,J,A,R,T

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:

M,J,A,R,T

MariaLiga

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,**J**,A,R,T

MariaLiga

JoãoLiga

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T

MariaLiga

JoãoLiga

$$P(J|M) = P(J)?$$

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T

MariaLiga


JoãoLiga

$P(J|M) = P(J)$? Não. Se Maria ligar, provavelmente o alarme disparou, o que aumenta a probabilidade de João ligar

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(J|M) = P(J)$? Não. Se Maria ligar, provavelmente o alarme disparou, o que aumenta a probabilidade de João ligar

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




Note que os candidatos a pai de X_i têm que estar entre os X_{i-1} anteriores

$P(J|M) = P(J)$? Não. Se Maria ligar, provavelmente o alarme disparou, o que aumenta a probabilidade de João ligar

Redes Bayesianas

Consequências da Ordem Errada


Devemos incluir
na ordem definida:
M,J,A,R,T



Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$$P(A|J, M) = P(A|J)?$$

$$P(A|J, M) = P(A|M)?$$

$$P(A|J, M) = P(A)?$$

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(A J, M) = P(A J)?$	}	Não. Se ambos ligarem, as chances do alarme ter disparado são maiores do que se apenas um ligar, ou se nenhum ligar
$P(A J, M) = P(A M)?$		
$P(A J, M) = P(A)?$		

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(A J, M) = P(A J)?$	}	Não. Se ambos ligarem, as chances do alarme ter disparado são maiores do que se apenas um ligar, ou se nenhum ligar
$P(A J, M) = P(A M)?$		
$P(A J, M) = P(A)?$		

Redes Bayesianas

Consequências da Ordem Errada


Devemos incluir
na ordem definida:
M,J,A,**R**,T



Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$$P(R|M, J, A) = P(R)?$$

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(R|M, J, A) = P(R)$? Não. Não é independente das demais

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(R|M, J, A) = P(R)$? Não. Não é independente das demais
 $P(R|M, J, A) = P(R|A)$?

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(R|M, J, A) = P(R)$? Não. Não é independente das demais

$P(R|M, J, A) = P(R|A)$? Sim. Se sabemos o estado do alarme, não importa se João ou Maria ligam

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(R|M, J, A) = P(R)$? Não. Não é independente das demais

$P(R|M, J, A) = P(R|A)$? Sim. Se sabemos o estado do
alarme, não importa se João ou Maria ligam

Redes Bayesianas

Consequências da Ordem Errada


Devemos incluir
na ordem definida:
M,J,A,R,**T**



Redes Bayesianas

Consequências da Ordem Errada


Devemos incluir
na ordem definida:
M,J,A,R,T



$$P(T|R, A, J, M) = P(T)?$$

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais
 $P(T|R, A, J, M) = P(T|A)$?

Redes Bayesianas

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais

$P(T|R, A, J, M) = P(T|A)$? Não

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais

$P(T|R, A, J, M) = P(T|A)$? Não

$P(T|R, A, J, M) = P(T|R, A)$?

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T




$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais

$P(T|R, A, J, M) = P(T|A)$? Não

$P(T|R, A, J, M) = P(T|R, A)$? Sim. Se o alarme estiver soando, aumenta a probabilidade de terremoto. Contudo, se soubermos que houve um roubo, isso explica o alarme, e a probabilidade do terremoto cai

Consequências da Ordem Errada

Devemos incluir
na ordem definida:
M,J,A,R,T



Fonte: Adaptado de AIMA. Russell & Norvig.

$P(T|R, A, J, M) = P(T)$? Não. Não é independente das demais


$P(T|R, A, J, M) = P(T|A)$? Não

$P(T|R, A, J, M) = P(T|R, A)$? Sim. Se o alarme estiver soando, aumenta a probabilidade de terremoto. Contudo, se soubermos que houve um roubo, isso explica o alarme, e a probabilidade do terremoto cai


Redes Bayesianas

Consequências da Ordem Errada

Ordem: M,J,A,R,T



Ordem: R,T,A,J,M




Fonte: Adaptado de AIMA. Russell & Norvig.


Redes Bayesianas

Consequências da Ordem Errada

Ordem: M,J,A,R,T



Ordem: R,T,A,J,M



Fonte: Adaptado de AIMA. Russell & Norvig.

A nova rede tem duas arestas a mais que a antiga

Redes Bayesianas

Construção Automática

- Vimos o caso em que a estrutura da rede é dada e temos os valores para todas as variáveis nos exemplos de treino

Construção Automática

- Vimos o caso em que a estrutura da rede é dada e temos os valores para todas as variáveis nos exemplos de treino
- Estimamos as tabelas de probabilidade condicional a partir dos dados

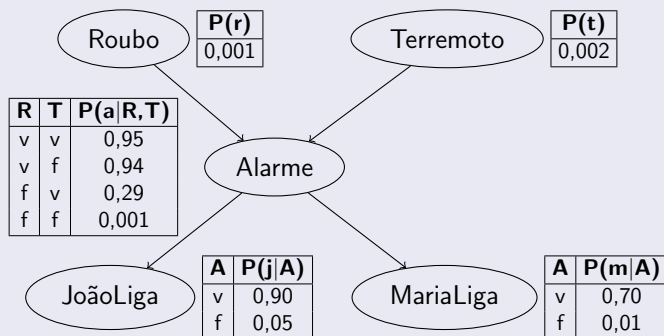
Construção Automática

- Vimos o caso em que a estrutura da rede é dada e temos os valores para todas as variáveis nos exemplos de treino
 - Estimamos as tabelas de probabilidade condicional a partir dos dados
- Podemos aprender também a estrutura a partir dos dados. Ex:
 - K2: Cooper and Herskovits (1992)
 - TAN: Friedman et al. (1997)
 - Simulated Annealing: Bouckaert (1995)

Redes Bayesianas

Inferência em Redes Bayesianas

- Considere a rede bayesiana:

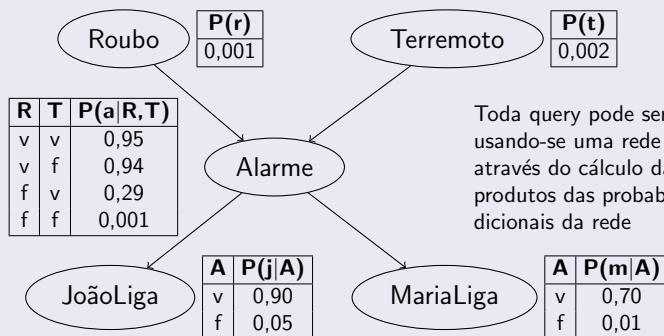


Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas

Inferência em Redes Bayesianas

- Considere a rede bayesiana:



Toda query pode ser respondida usando-se uma rede bayesiana através do cálculo das somas dos produtos das probabilidades condicionais da rede

Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

$$P(r, j, m) = \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A)$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

$$P(r, j, m) = \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A)$$

Como não definimos valores para T e A , temos que fazer todas as combinações de valores possíveis



Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

$$P(r, j, m) = \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A)$$

$$= \sum_{T=\{v, f\}} P(r, j, m, T, a) + P(r, j, m, T, \neg a)$$

Como não definimos valores para T e A , temos que fazer todas as combinações de valores possíveis



Inferência em Redes Bayesianas – Exemplo

- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

$$\begin{aligned} P(r, j, m) &= \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A) \\ &= \sum_{T=\{v, f\}} P(r, j, m, T, a) + P(r, j, m, T, \neg a) \\ &= P(r, j, m, t, a) + P(r, j, m, t, \neg a) + \\ &\quad P(r, j, m, \neg t, a) + P(r, j, m, \neg t, \neg a) \end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

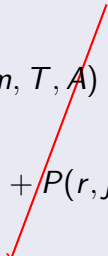
- Query: $P(r|j, m) = ?$

$$P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$$

$$P(r, j, m) = \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A)$$
$$= \sum_{T=\{v, f\}} P(r, j, m, T, a) + P(r, j, m, T, \neg a)$$

$$= P(r, j, m, t, a) + P(r, j, m, t, \neg a) + P(r, j, m, \neg t, a) + P(r, j, m, \neg t, \neg a)$$

A query foi reescrita como uma soma de probabilidades conjuntas



Inferência em Redes Bayesianas – Exemplo

$$P(r, j, m, t, a) = P(r)P(j, m, t, a|r)$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\ &= P(r)P(t)P(j, m, a|r, t)\end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(\textcolor{red}{r})P(j, m, t, a|r) \\ &= P(\textcolor{red}{r})P(\textcolor{red}{t})P(j, m, a|r, t)\end{aligned}$$

A escolha de R e
 T deu-se por serem
raízes na árvore

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a)\end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a)\end{aligned}$$

A foi escolhido por depender unicamente das variáveis já isoladas (T e R)

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a)\end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a)\end{aligned}$$

j não depende de *r* e *t*

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a) \\&= P(r)P(t)P(a|r, t)P(j|a)P(m|a)\end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a) \\&= P(r)P(t)P(a|r, t)P(j|a)P(m|a)\end{aligned}$$

Note que se trata de
cada nó da rede

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a) \\&= P(r)P(t)P(a|r, t)P(j|a)P(m|a)\end{aligned}$$

Assim, derivando-se as demais de modo similar, teremos:

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

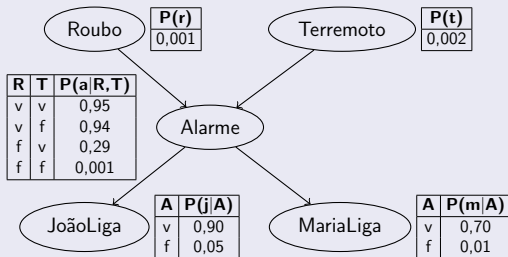
$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(j, m, t, a|r) \\&= P(r)P(t)P(j, m, a|r, t) \\&= P(r)P(t)P(a|r, t)P(j, m|r, t, a) \\&= P(r)P(t)P(a|r, t)P(j, m|a) \\&= P(r)P(t)P(a|r, t)P(j|a)P(m|a)\end{aligned}$$

Assim, derivando-se as demais de modo similar, teremos:

$$\begin{aligned}P(r, j, m, t, \neg a) &= P(r)P(t)P(\neg a|r, t)P(j|\neg a)P(m|\neg a) \\P(r, j, m, \neg t, a) &= P(r)P(\neg t)P(a|r, \neg t)P(j|a)P(m|a) \\P(r, j, m, \neg t, \neg a) &= P(r)P(\neg t)P(\neg a|r, \neg t)P(j|\neg a)P(m|\neg a)\end{aligned}$$

Redes Bayesianas


Inferência em Redes Bayesianas – Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo

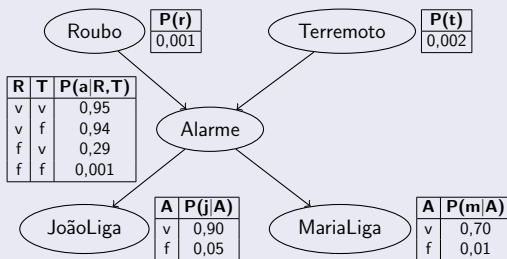


Fonte: Adaptado de AIMA. Russell & Norvig.

$$P(r, j, m, t, a) = P(r)P(t)P(a|r, t)P(j|a)P(m|a) \approx 1,197 \times 10^{-6}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo




Fonte: Adaptado de AIMA. Russell & Norvig.

$$P(r, j, m, t, a) = P(r)P(t)P(a|r, t)P(j|a)P(m|a) \approx 1,197 \times 10^{-6}$$

$$P(r, j, m, t, \neg a) = P(r)P(t)P(\neg a|r, t)P(j|\neg a)P(m|\neg a) \approx 5 \times 10^{-11}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo




Fonte: Adaptado de AIMA. Russell & Norvig.

$$\begin{aligned}P(r, j, m, t, a) &= P(r)P(t)P(a|r, t)P(j|a)P(m|a) && \approx 1,197 \times 10^{-6} \\P(r, j, m, t, \neg a) &= P(r)P(t)P(\neg a|r, t)P(j|\neg a)P(m|\neg a) && \approx 5 \times 10^{-11} \\P(r, j, m, \neg t, a) &= P(r)P(\neg t)P(a|r, \neg t)P(j|a)P(m|a) && \approx 5,91 \times 10^{-4}\end{aligned}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

$$P(r, j, m, t, a) = P(r)P(t)P(a|r, t)P(j|a)P(m|a) \approx 1,197 \times 10^{-6}$$

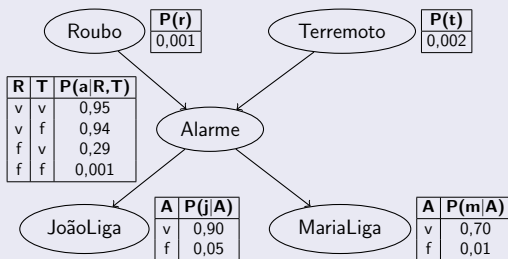
$$P(r, j, m, t, \neg a) = P(r)P(t)P(\neg a|r, t)P(j|\neg a)P(m|\neg a) \approx 5 \times 10^{-11}$$

$$P(r, j, m, \neg t, a) = P(r)P(\neg t)P(a|r, \neg t)P(j|a)P(m|a) \approx 5,91 \times 10^{-4}$$

$$P(r, j, m, \neg t, \neg a) = P(r)P(\neg t)P(\neg a|r, \neg t)P(j|\neg a)P(m|\neg a) \approx 2,994 \times 10^{-6}$$

Redes Bayesianas

Inferência em Redes Bayesianas – Exemplo



Fonte: Adaptado de AIMA. Russell & Norvig.

$$P(r, j, m, t, a) = P(r)P(t)P(a|r, t)P(j|a)P(m|a) \approx 1,197 \times 10^{-6}$$

$$P(r, j, m, t, \neg a) = P(r)P(t)P(\neg a|r, t)P(j|\neg a)P(m|\neg a) \approx 5 \times 10^{-11}$$

$$P(r, j, m, \neg t, a) = P(r)P(\neg t)P(a|r, \neg t)P(j|a)P(m|a) \approx 5,91 \times 10^{-4}$$

$$P(r, j, m, \neg t, \neg a) = P(r)P(\neg t)P(\neg a|r, \neg t)P(j|\neg a)P(m|\neg a) \approx 2,994 \times 10^{-6}$$

$$P(r, j, m) = \sum_{T=\{v, f\}} \sum_{A=\{v, f\}} P(r, j, m, T, A) \approx 0,00059224$$

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$
 - Já calculamos $P(r, j, m)$

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$
 - Já calculamos $P(r, j, m)$
 - Falta $P(j, m)$

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$
 - Já calculamos $P(r, j, m)$
 - Falta $P(j, m)$
- Contudo, $P(j, m)$ não precisa ser calculado diretamente:

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$
 - Já calculamos $P(r, j, m)$
 - Falta $P(j, m)$
- Contudo, $P(j, m)$ não precisa ser calculado diretamente:
 - Podemos calcular $P(\neg r, j, m)$ pelo mesmo método que calculamos $P(r, j, m)$

Inferência em Redes Bayesianas – Exemplo

- Lembre que queríamos $P(r|j, m) = \frac{P(r, j, m)}{P(j, m)}$
 - Já calculamos $P(r, j, m)$
 - Falta $P(j, m)$
- Contudo, $P(j, m)$ não precisa ser calculado diretamente:
 - Podemos calcular $P(\neg r, j, m)$ pelo mesmo método que calculamos $P(r, j, m)$
 - Nesse caso teríamos $P(\neg r, j, m) \approx 0,0014919$

Inferência em Redes Bayesianas – Exemplo

- Lembre que $P(\neg r|j, m) + P(r|j, m) = 1$

Inferência em Redes Bayesianas – Exemplo

- Lembre que $P(\neg r|j, m) + P(r|j, m) = 1$
- Assim:

$$\begin{aligned} P(r|j, m) + P(\neg r|j, m) &= \frac{P(r, j, m)}{P(j, m)} + \frac{P(\neg r, j, m)}{P(j, m)} \\ &= \alpha \times [P(r, j, m) + P(\neg r, j, m)] \end{aligned}$$

com $\alpha = \frac{1}{P(j, m)}$ sendo a **constante de normalização**

Inferência em Redes Bayesianas – Exemplo

- Como $P(\neg r|j, m) + P(r|j, m) = 1$, temos que

$$\alpha \times [P(r, j, m) + P(\neg r, j, m)] = 1$$

$$\Rightarrow \alpha \times [0,00059224 + 0,0014919] = 1$$

$$\Rightarrow \alpha = \frac{1}{P(j, m)} \approx 479,81$$

Inferência em Redes Bayesianas – Exemplo

- Como $P(\neg r|j, m) + P(r|j, m) = 1$, temos que

$$\alpha \times [P(r, j, m) + P(\neg r, j, m)] = 1$$

$$\Rightarrow \alpha \times [0,00059224 + 0,0014919] = 1$$

$$\Rightarrow \alpha = \frac{1}{P(j, m)} \approx 479,81$$

Levando a

$$P(r|j, m) = \alpha \times P(r, j, m) \approx 0,284 = 28,4\%$$

$$P(\neg r|j, m) = \alpha \times P(\neg r, j, m) \approx 0,716 = 71,6\%$$

Inferência em Redes Bayesianas – Em Suma

- Para calcular qualquer combinação de valores:

Inferência em Redes Bayesianas – Em Suma

- Para calcular qualquer combinação de valores:
 - Identifique que variáveis estão na rede e não receberam valor

Inferência em Redes Bayesianas – Em Suma

- Para calcular qualquer combinação de valores:
 - Identifique que variáveis estão na rede e não receberam valor
 - Faça todas as combinações de valores com essas variáveis + os valores fixos definidos no problema, somando-as

Inferência em Redes Bayesianas – Em Suma

- Para calcular qualquer combinação de valores:
 - Identifique que variáveis estão na rede e não receberam valor
 - Faça todas as combinações de valores com essas variáveis + os valores fixos definidos no problema, somando-as
 - Cada combinação é calculada multiplicando-se as probabilidades de cada nó na rede, para os valores definidos pela combinação

Redes Bayesianas

Inferência em Redes Bayesianas

- Problemas:

Redes Bayesianas

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso

Redes Bayesianas

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)
- Solução:

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)
- Solução:
 - Usar métodos para inferência aproximada

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)
- Solução:
 - Usar métodos para inferência aproximada
 - Amostragem direta

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)
- Solução:
 - Usar métodos para inferência aproximada
 - Amostragem direta
 - Algoritmos do tipo Markov Chain Monte Carlo (MCMC), como *simulated annealing* e *Gibbs sampling*

Inferência em Redes Bayesianas

- Problemas:
 - Método bastante trabalhoso
 - No pior caso, intratável (NP-difícil)
- Solução:
 - Usar métodos para inferência aproximada
 - Amostragem direta
 - Algoritmos do tipo Markov Chain Monte Carlo (MCMC), como *simulated annealing* e *Gibbs sampling*
 - Mesmo esses podem ser NP-difíceis, embora em muitos casos úteis

Redes Bayesianas

Variáveis Contínuas

Variáveis Contínuas

- Duas abordagens:

Redes Bayesianas

Variáveis Contínuas

- Duas abordagens:
 - Discretização

Variáveis Contínuas

- Duas abordagens:
 - Discretização
 - Separe os valores contínuos em intervalos discretos

Variáveis Contínuas

- Duas abordagens:
 - Discretização
 - Separe os valores contínuos em intervalos discretos
 - Há perda de precisão

Variáveis Contínuas


- Duas abordagens:
 - Discretização
 - Separe os valores contínuos em intervalos discretos
 - Há perda de precisão
 - Pode resultar em grande número de valores

Variáveis Contínuas

- Duas abordagens:
 - Discretização
 - Separe os valores contínuos em intervalos discretos
 - Há perda de precisão
 - Pode resultar em grande número de valores
 - Use uma função de densidade de probabilidade como aproximação para $P(A|B)$. Ex:

Variáveis Contínuas

- Duas abordagens:
 - Discretização
 - Separe os valores contínuos em intervalos discretos
 - Há perda de precisão
 - Pode resultar em grande número de valores
 - Use uma função de densidade de probabilidade como aproximação para $P(A|B)$. Ex:



Fonte: <https://coloneltdcampbell.blog/2016/02/13/the-800-pound-gorillas/normal67/>

$$\begin{aligned} P(x) &= \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\ &= N(\mu, \sigma^2) \end{aligned}$$

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

Redes Bayesianas – Variáveis Contínuas


Usando uma função de densidade:

- Suponha que queremos modelar a medição de temperatura em uma determinada sala, usando um termômetro

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:


- Suponha que queremos modelar a medição de temperatura em uma determinada sala, usando um termômetro



Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Suponha que queremos modelar a medição de temperatura em uma determinada sala, usando um termômetro




- O termômetro (sensor), contudo, não é perfeito

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Suponha que queremos modelar a medição de temperatura em uma determinada sala, usando um termômetro




- O termômetro (sensor), contudo, não é perfeito
 - Mede em torno da temperatura real, mas não exatamente

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Suponha que queremos modelar a medição de temperatura em uma determinada sala, usando um termômetro



- O termômetro (sensor), contudo, não é perfeito
 - Mede em torno da temperatura real, mas não exatamente
 - $S \approx N(t; \sigma_S^2) \rightarrow$ normal centrada em t , com desvio padrão σ_S

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Agora imagine que queremos poder inferir como estará a temperatura na sala daqui a alguns instantes


Usando uma função de densidade:

- Agora imagine que queremos poder inferir como estará a temperatura na sala daqui a alguns instantes
- Essa depende, no entanto, da temperatura atual e da temperatura externa, dado que sempre há uma troca de calor com o exterior

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:


- Agora imagine que queremos poder inferir como estará a temperatura na sala daqui a alguns instantes
- Essa depende, no entanto, da temperatura atual e da temperatura externa, dado que sempre há uma troca de calor com o exterior
- Temos então:



Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Um possível modelo para T_f seria




$$T_f \approx N(\alpha T + (1-\alpha) T_e, \sigma_{T_f}^2)$$

Fonte: Coursera (Cont. Variables). Koller.

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Um possível modelo para T_f seria



Fonte: Coursera (Cont. Variables). Koller.


$$T_f \approx N(\alpha T + (1 - \alpha) T_e, \sigma_{T_f}^2)$$

centrada na média ponderada das temperaturas no momento atual (T) e externa (T_e)

Redes Bayesianas – Variáveis Contínuas

Usando uma função de densidade:

- Um possível modelo para T_f seria



Fonte: Coursera (Cont. Variables). Koller.


$$T_f \approx N(\alpha T + (1 - \alpha) T_e, \sigma_{T_f}^2)$$

centrada na média ponderada das temperaturas no momento atual (T) e externa (T_e)

Modelo Linear Gaussiano

Mistura Discretas + Contínuas – Exemplo


- Alguém vai comprar frutas, dependendo do preço



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo

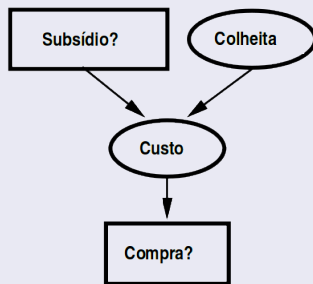
- Alguém vai comprar frutas, dependendo do preço
- O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo


- Alguém vai comprar frutas, dependendo do preço
- O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios
- Variáveis contínuas



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo

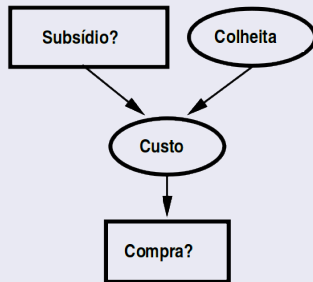
- Alguém vai comprar frutas, dependendo do preço
 - O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios
- Variáveis contínuas
 - Custo e Colheita



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo


- Alguém vai comprar frutas, dependendo do preço
 - O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios
- Variáveis contínuas
 - Custo e Colheita
- Variáveis discretas



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo


- Alguém vai comprar frutas, dependendo do preço
 - O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios
- Variáveis contínuas
 - Custo e Colheita
- Variáveis discretas
 - Subsídio (Sim ou não)



Fonte: Slides de AIMA. Russell & Norvig.

Mistura Discretas + Contínuas – Exemplo

- Alguém vai comprar frutas, dependendo do preço
 - O preço depende do tamanho da colheita e do fato do governo ter dado ou não subsídios
- Variáveis contínuas
 - Custo e Colheita
- Variáveis discretas
 - Subsídio (Sim ou não)
 - Compra (Sim ou não)

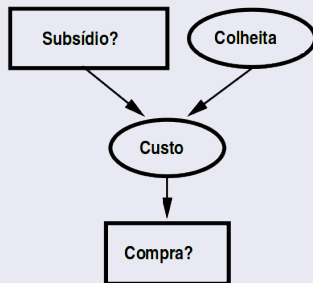


Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis contínuas com pais mistos

- Modelamos uma dependência contínua-contínua com um dos pais, para cada valor discreto do outro pai




Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis contínuas com pais mistos

- Modelamos uma dependência contínua-contínua com um dos pais, para cada valor discreto do outro pai

- $P(\text{Custo} | \text{Colheita}, \text{subsídio}) = \frac{1}{\sigma_v \sqrt{2\pi}} e^{\frac{-(\text{Custo} - (a_v \times \text{Colheita} + b_v))^2}{2\sigma_v^2}}$



Fonte: Slides de AIMA. Russell & Norvig.

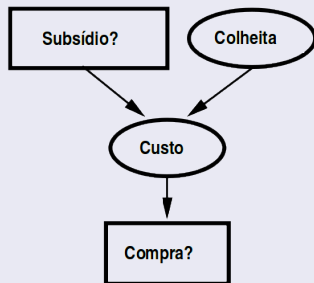
Redes Híbridas – Exemplo

Variáveis contínuas com pais mistos

- Modelamos uma dependência contínua-contínua com um dos pais, para cada valor discreto do outro pai

- $$P(\text{Custo} | \text{Colheita}, \text{subsídio}) = \frac{1}{\sigma_v \sqrt{2\pi}} e^{-\frac{(\text{Custo} - (a_v \times \text{Colheita} + b_v))^2}{2\sigma_v^2}}$$

- $$P(\text{Custo} | \text{Colheita}, \neg \text{subsídio}) = \frac{1}{\sigma_f \sqrt{2\pi}} e^{-\frac{(\text{Custo} - (a_f \times \text{Colheita} + b_f))^2}{2\sigma_f^2}}$$




Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis contínuas com pais discretos


$P(\text{Custo} | \text{Colheita}, \text{subsídio}=V)$



Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis discretas com pais contínuos:

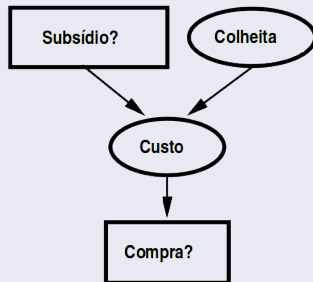


Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis discretas com pais contínuos:

- A distribuição deve seguir um degrau suave




Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis discretas com pais contínuos:

- A distribuição deve seguir um degrau suave
- Espera-se que o cliente compre se o custo for baixo e não compre se for alto, sendo que a probabilidade entre esses valores varia suavemente




Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis discretas com pais contínuos:

- A distribuição deve seguir um degrau suave
- Espera-se que o cliente compre se o custo for baixo e não compre se for alto, sendo que a probabilidade entre esses valores varia suavemente
- Um meio de fazer tais degraus é usar a integral da distribuição normal




Fonte: Slides de AIMA. Russell & Norvig.

Redes Híbridas – Exemplo

Variáveis discretas com pais contínuos:

$$\Phi(x) = \int_{-\infty}^x N(0, 1)(x) dx$$



Fonte: Slides de AIMA. Russell & Norvig.


$$P(\text{comprar} | \text{Custo} = c) = \Phi\left(\frac{-c + \mu}{\sigma}\right)$$

O degrau vai ocorrer ao redor de μ

Redes Bayesianas

Justificativa para a Gaussiana

- Pode ser vista como um degrau normal, cuja localização precisa está sujeita a ruído aleatório normalmente distribuído:




Fonte: Slides de AIMA. Russell & Norvig.

Redes Bayesianas

Alternativa à Integral da Gaussiana

- Usar uma função sigmoide:

$$P(\text{comprar} | \text{Custo} = c) = \frac{1}{1 + e^{-2 \frac{-c + \mu}{\sigma}}}$$



Similar à integral da Gaussiana, porém mais alongada

Fonte: Slides de AIMA. Russell & Norvig.

Referências

- Russell, S.; Norvig P. (2010): Artificial Intelligence: A Modern Approach. Prentice Hall. 3a ed.
 - Slides do livro: aima.eecs.berkeley.edu/slides-pdf/
- Mitchell, T.M.: Machine Learning. McGraw-Hill. 1997.
- Murphy, K. P.: Machine Learning: A Probabilistic Perspective. MIT Press. 2012.
- Cover, T.M.; Thomas, J.A.: Elements of Information Theory. 2 ed. Wiley. 2006.
- Alpaydm, E.: Introduction to Machine Learning. 2 ed. MIT Press. 2010.

Referências

- Bouckaert, R.R.: Bayesian Belief Networks: from Construction to Inference. Ph.D. thesis. University of Utrecht. 1995.
- Cheng, J.; Greiner, R.: Comparing bayesian network classifiers. Proceedings UAI, 101–107. 1999.
- Cooper, G.; Herskovits, E.: A Bayesian method for the induction of probabilistic networks from data. Machine Learning, 9: 309–347. 1992.
- Duda, R.O.; Hart, P.E.; Stork, D.G.: Pattern Classification. 2 ed. Wiley. 2001.
- Friedman, N.; Geiger, D.; Goldszmidt, M.: Bayesian Network Classifiers. Machine Learning, 29: 131–163. 1997.
- Koller, D.: <https://pt.coursera.org/lecture/probabilistic-graphical-models/continuous-variables-wkNmM>