





Inteligência Artificial

Sexta Lista de Exercícios – Gabarito

Prof. Norton Trevisan Roman

23 de maio de 2019

1. Há mais de uma árvore possível, dependendo do argumento testado antes



2. (a)

$$\begin{aligned}
H(S) = I(S) &= - \sum_{i=1}^n P(v_i) \log_2 P(v_i) \\
&= - \frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} \\
&= - \log_2 \frac{3}{6} = 1
\end{aligned}$$

$$(b) \ G(S, a_2) = I\left(\frac{p}{n+p}, \frac{n}{n+p}\right) - R(S, a_2)$$

$$\begin{aligned}
R(S, a_2) &= \frac{p_T + n_T}{p+n} I\left(\frac{p_T}{p_T + n_T}, \frac{n_T}{p_T + n_T}\right) + \frac{p_F + n_F}{p+n} I\left(\frac{p_F}{p_F + n_F}, \frac{n_F}{p_F + n_F}\right) \\
&= \frac{2+2}{3+3} I\left(\frac{2}{2+2}, \frac{2}{2+2}\right) + \frac{1+1}{3+3} I\left(\frac{1}{1+1}, \frac{1}{1+1}\right) \\
&= \frac{2}{3} I\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{1}{3} I\left(\frac{1}{2}, \frac{1}{2}\right) \\
&= \frac{2}{3} + \frac{1}{3} = 1
\end{aligned}$$

$$\text{Então } G(S, a_2) = 1 - 1 = 0$$

3. Calculamos primeiro a necessidade de informação do conjunto todo

$$I(y) = -\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \approx 0,971$$

E então os Restantes:

$$R(A_1) = \frac{0+1}{5} I\left(\frac{0}{1}, \frac{1}{1}\right) + \frac{2+2}{5} I\left(\frac{2}{4}, \frac{2}{4}\right) = 0,8$$

$$R(A_2) = \frac{0+2}{5} I\left(\frac{0}{2}, \frac{2}{2}\right) + \frac{2+1}{5} I\left(\frac{2}{3}, \frac{1}{3}\right) \approx 0,551$$

$$R(A_3) = \frac{1+2}{5} I\left(\frac{1}{3}, \frac{2}{3}\right) + \frac{1+1}{5} I\left(\frac{1}{2}, \frac{1}{2}\right) \approx 0,951$$

O ganho de cada atributo será então

Atributo	Ganho
A_1	0,171
A_2	0,420
A_3	0,020

Escolhemos A_2 como raiz então, pois tem maior ganho (alternativamente, por ter menor necessidade restante). Separando os dados pelos valores de A_2 temos:

Ex	A_1	A_2	A_3	y
x_1	1	0	0	0
x_2	1	0	1	0

Ex	A_1	A_2	A_3	y
x_3	0	1	0	0
x_4	1	1	1	1
x_5	1	1	0	1

E vemos que, se $A_2 = 0$, então $y = 0$. Passamos agora aos dados em que $A_2 = 1$, lembrando o valor da necessidade de informação do conjunto (já feito acima):

$$I(A_2 = 1) = I\left(\frac{2}{3}, \frac{1}{3}\right) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \approx 0,918$$

E os novos restantes:

$$R(A_1) = \frac{0+1}{3} I\left(\frac{0}{1}, \frac{1}{1}\right) + \frac{2+0}{3} I\left(\frac{2}{2}, \frac{0}{2}\right) = 0$$


$$R(A_3) = \frac{1+1}{3} I\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{1+0}{3} I\left(\frac{1}{1}, \frac{0}{1}\right) \approx 0,667$$

E nossa próxima escolha é A_1 , que nos deixa com restante nulo. Filtrando os dados pelos valores de A_1 temos:

Ex	A_1	A_2	A_3	y
x_3	0	1	0	0

Ex	A_1	A_2	A_3	y
x_4	1	1	1	1
x_5	1	1	0	1

Temos então a árvore:



4. O conteúdo de informação de um atributo foi apresentado em aula:

$$I(A) = I(P(v_1), \dots, P(v_n)) = - \sum_{i=1}^n P(v_i) \log_2 P(v_i)$$


A implementação da razão do ganho substitui o critério

$$Ganho(A) = I\left(\frac{p}{p+n}, \frac{n}{p+n}\right) - Restante(S, A) \text{ (onde } A \text{ é o atributo)}$$


e é definida como

$$Z(A) = \frac{Ganho(A)}{I(A)} = \frac{I(A) - Restante(A)}{I(A)} = 1 - \frac{Restante(A)}{I(A)}$$


- 5.




6. Lembre que $A \oplus B = (A \wedge \neg B) \vee (\neg A \wedge B)$. Do exercício anterior temos uma rede $A \wedge \neg B$:



De forma semelhante, podemos fazer uma rede $A \wedge B$:



$A \oplus B$ será então a união dessas com um OR:



7. Usando a função de erro vista em aula

$$E(\vec{\omega}) = \frac{1}{2} \sum_{d \in D} (t_d - s_d)^2$$

precisamos calcular o gradiente do erro

$$\nabla E(\vec{\omega}) = \left[\frac{\partial E}{\partial \omega_0}, \frac{\partial E}{\partial \omega_1}, \dots, \frac{\partial E}{\partial \omega_n} \right]$$

Então

$$\begin{aligned}
\frac{\partial}{\partial \omega_i} E(\vec{\omega}) &= \frac{1}{2} \sum_{d \in D} \frac{\partial}{\partial \omega_i} (t_d - s_d)^2 \\
&= \sum_{d \in D} (t_d - s_d) \frac{\partial}{\partial \omega_i} (t_d - s_d) \\
&= - \sum_{d \in D} (t_d - s_d) \frac{\partial}{\partial \omega_i} s_d
\end{aligned}$$

Uma vez que $s_d = \omega_o + \omega_1 x_{1d} + \omega_1 x_{1d}^2 + \dots + \omega_n x_{nd} + \omega_n x_{nd}^2$, temos então 2 situações:


$$\begin{aligned}
\text{(a) } i = 0, \text{ e } \frac{\partial}{\partial \omega_0} s_d = 1 &\Rightarrow \frac{\partial}{\partial \omega_0} E(\vec{\omega}) = - \sum_{d \in D} (t_d - s_d) \\
\text{(b) } i > 0, \text{ e } \frac{\partial}{\partial \omega_i} s_d = x_{id} + x_{id}^2 &\Rightarrow \frac{\partial}{\partial \omega_i} E(\vec{\omega}) = - \sum_{d \in D} (t_d - s_d)(x_{id} + x_{id}^2)
\end{aligned}$$

8. Para responder a essa questão, precisamos ver como os exemplos serão classificados por essas funções de ativação:

$$A: \quad 1 + 2x_1 + 1x_2 > 0$$

$$B: \quad 2x_1 + 1x_2 > 0$$

Olhando as equações, podemos ver que todo valor que resulte > 0 em B certamente irá resultar > 0 em A , uma vez que $A = B + 1$ (já o contrário não é verdade). Então $(B = 1) \Rightarrow (A = 1)$, e A é mais geral que B . Outra forma de verificarmos isso é graficar as funções A e B . Para isso, note que um sinal passará em A toda vez que $x_2 > -2x_1 - 1$, e em B toda vez que $x_2 > -2x_1$. Então



e notamos que todo ponto acima de B também estará acima de A

9. A equação

$$\Delta \omega_i = \eta(t - s)x_i$$

corresponde ao gradiente incremental no qual os pesos são atualizados após vermos cada um dos exemplos. Já a equação

$$\Delta \omega_i = \eta \sum_{d \in D} (t_d - s_d)x_{i,d}$$

corresponde ao gradiente descendente no qual os pesos são atualizados após vermos todos os exemplos uma vez. Então a primeira nada mais é que a segunda para um único exemplo.