

ACH2016 - Inteligência Artificial

Aula 04 - Regressão Linear

Valdinei Freire da Silva

valdinei.freire@usp.br - Bloco A1 100-O

Russell e Norvig, Capítulo 18

Tarefa de Aprendizado Supervisionado

Dado um conjunto de treinamento com N exemplos de pares entrada-saída

$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N),$$

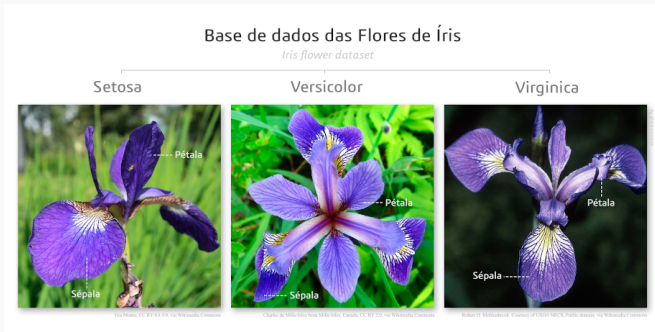
onde cada y_i foi gerado por uma função f desconhecida, isto é, $y_i = f(x_i)$.

Descubra uma função h que aproxima a verdadeira função f .

x é a entrada e y é a saída.


x e y podem ser qualquer valor, números ou categorias, x usualmente é um vetor de valores (atributos).

Banco de Dados Iris




Atributos:

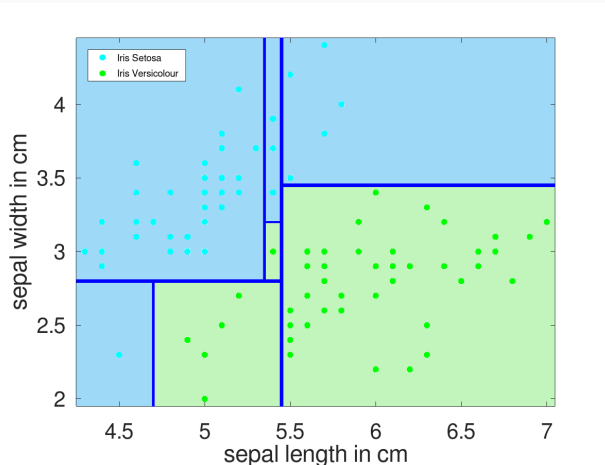
- comprimento da sépala
- largura da sépala
- comprimento da pétala
- largura da pétala



Banco de Dados Iris



Banco de Dados Iris - Árvore de Decisão



Classificação Linear

Classificação Binária Linear (d atributos)

$$h_w(x) = \begin{cases} 1, & \text{se } w^T x > 0 \\ 0, & \text{caso contrário} \end{cases}$$

x é o vetor de entradas (d atributos) adicionado de um atributo “dummy” com valor fixo 1.

w é o vetor de pesos ($d + 1$ dimensões).

w^T é o transposto do vetor w .

$w^T x$ é a multiplicação matricial.

Como encontrar o vetor w que classifique adequadamente os dados da amostras?

A seguinte regra pode ser utilizada para tentar melhorar um vetor w_t :

- sorteie um vetor de pesos iniciais w_0 e repita os passos abaixo
- sorteie aleatoriamente um exemplo $e_i = (x_i, y_i)$
- atualize o vetor w_t

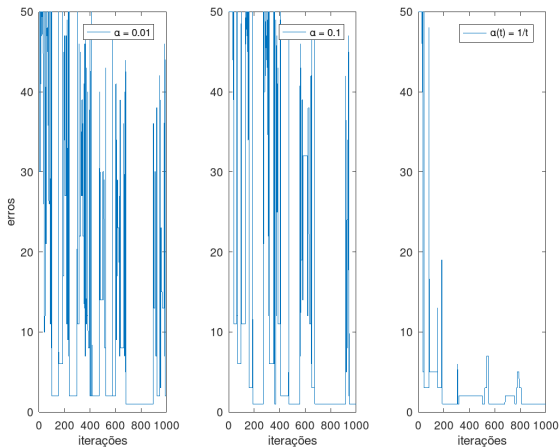
$$w_{t+1} \leftarrow w_t + \alpha_t (y_i - h_{w_t}(x_i)) x_i$$

onde α_t é a taxa de aprendizado no tempo t .


- se a saída $h_w(x)$ está correta nenhuma alteração é realizada
- se $y = 1$, mas $h_w(x) = 0$, então w_i é aumentado se x_i é positivo, e diminuído quando x_i é negativo, isso faz com que $w^T x$ aumente.
- se $y = 0$, mas $h_w(x) = 1$, então w_i é aumentado se x_i é negativo, e diminuído quando x_i é positivo, isso faz com que $w^T x$ diminua.
- converge se

$$\sum_{t=1}^{\infty} \alpha_t = \infty \text{ e } \sum_{t=1}^{\infty} (\alpha_t)^2 < \infty$$


Classificação Linear (1 repetição)



Classificação Linear (1000 repetições)



Classificação Linear



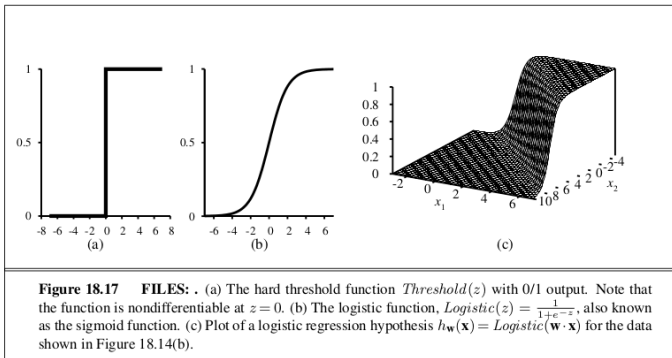
Classificação Linear com Regressão Logística

Classificação Binária Linear de Múltiplas Variáveis (d variáveis)


$$h_w(\mathbf{x}) = \text{Logistic}(w^\top \mathbf{x}) = \frac{1}{1 + e^{-w^\top \mathbf{x}}}$$

\mathbf{x} é o vetor de entrada adicionado de um atributo “dummy” com valor fixo 1.

Classifica como 1 se $h_w(\mathbf{x}) > \beta$, e 0 caso contrário.



Classificação Linear com Regressão Logística



Classificação Linear com Regressão Logística

Considere $h_w(x_i)$ como sendo a probabilidade da entrada x_i ser classificada como 1 e definida a função perda (*loss function*) como sendo o *negative log-likelihood*:

$$Loss(h_w) = - \sum_{i=1}^n y_i h_w(x_i) + (1 - y_i)(1 - h_w(x_i))$$

Solução:

$$\min_{w \in \mathbb{R}^{d+1}} Loss(h_w) \Rightarrow \nabla_w Loss(h_w) = 0$$

Pode-se encontrar iterativamente:

$$w_{t+1} \leftarrow w_t - \alpha_t \nabla_{w_t} Loss(h_{w_t})$$

$$\nabla_{w_t} Loss(h_{w_t}) = - \sum_{i=1}^n (y_i - h_{w_t}(x_i)) x_i$$

Classificação Linear com Regressão Logística

Versão Batch (batelada ou em lote):

- sorteie um vetor de pesos w_0 e repita o passo abaixo
- atualize o vetor w_t .


$$w_{t+1} \leftarrow w_t + \alpha_t \sum_{i=1}^n (y_i - h_{w_t}(x_i)) x_i$$

Versão Estocástica:

- sorteie um vetor de pesos w_0 e repita os passos abaixo
- sorteie aleatoriamente um exemplo $e_i = (x_i, y_i)$
- atualize o vetor w_t .


$$w_{t+1} \leftarrow w_t + \alpha_t (y_i - h_{w_t}(x_i)) x_i$$

Regressão Logística (1 repetição - estocástica)




Regressão Logística (1 repetição - batelada)

α' inversamente proporcional a quantidade de exemplos ($\alpha/100$)



Regressão Logística (1000 repetições - estocástica)



Regressão Logística (1000 repetições - batelada)

α' inversamente proporcional a quantidade de exemplos ($\alpha/100$)

